

Quantum algorithms for supervised and unsupervised machine learning Seth Lloyd<sup>1,3</sup>, Masoud Mohseni<sup>2</sup>, Patrick Rebentrost<sup>1</sup> 1. Massachusetts Institute of Technology, Research Laboratory for Electronics 2. Google Research 3. To whom correspondence should be addressed: [slloyd@mit.edu](mailto:slloyd@mit.edu)

## Tinjauan Mendalam Artikel Penelitian Machine Learning Kuantum

### Kontribusi Utama Penelitian

#### 1. Percepatan Eksponensial:

- Artikel ini menunjukkan bahwa algoritma kuantum dapat menyelesaikan tugas *supervised* (klasifikasi kluster) dan *unsupervised* (pengelompokan k-means) dengan kompleksitas waktu **logaritmik** dalam jumlah vektor ( $M$ ) dan dimensi ( $N$ ), sementara algoritma klasik memerlukan waktu polinomial ( $O(\text{poly}(MN))$ ).
- Contoh konkret: Algoritma kuantum untuk *cluster assignment* hanya membutuhkan waktu  $O(\log(MN))$ , dibandingkan  $O(MN)$  pada klasik.

#### 2. Algoritma Kuantum untuk K-Means:

- Versi kuantum dari algoritma Lloyd (*quantum Lloyd's algorithm*) menggunakan pendekatan adiabatik kuantum untuk mengelompokkan  $M$  vektor ke  $k$  kluster dalam waktu  $O(k \log kMN)$ , jauh lebih efisien daripada  $O(M^2N)$  pada klasik.

#### 3. Peningkatan Privasi:

- Pengguna hanya perlu mengakses  $O(\log(MN))$  bit kuantum untuk tugas klasifikasi, sementara pemilik data tetap aman karena sebagian besar data tidak terekspos.

#### 4. Generalisasi ke Metrik Nonlinier:

- Algoritma dapat diperluas untuk menghitung jarak nonlinier menggunakan operasi kuantum, seperti polinomial tingkat tinggi pada komponen vektor.

### Rincian Algoritma Kuantum yang Diusulkan

#### 1. Supervised Cluster Assignment:

- **Swap Test:** Digunakan untuk mengukur jarak antara vektor uji ( $|u\rangle$ ) dan rata-rata kluster ( $V$  atau  $W$ ).
  - State  $|\phi\rangle = 1/\sqrt{2} (|0\rangle|u\rangle + 1/\sqrt{M} \sum_j |j\rangle|v_j\rangle)$  disiapkan, lalu diukur untuk menghitung probabilitas sukses yang terkait dengan jarak.
- **Quantum Counting:** Memperkirakan normalisasi  $Z$  dengan kompleksitas  $O(\epsilon^{-1} \log M)$ .

#### 2. Unsupervised Quantum Learning (k-means):

- **Algoritma Adiabatik Kuantum:**
  - **Persiapan State Awal:** Superposisi seragam label vektor ( $|\psi\rangle = 1/\sqrt{M} \sum_j |j\rangle$ ).
  - **Hamiltonian Final:** Dirancang untuk memaksimalkan jarak antar benih kluster (seperti  $H_s = -\sum_{\ell, \ell'} |v_j \ell - v_{j'} \ell'|^2$ ) atau meminimalkan jarak dalam kluster ( $H_c$ ).
  - **Output:** State  $|\chi\rangle = 1/\sqrt{M} \sum_{c, j \in c} |c\rangle|j\rangle$  yang merepresentasikan pengelompokan dalam superposisi kuantum.

#### 3. Ekstensi ke Nonlinieritas:

- Menggunakan *quantum phase algorithm* untuk menghitung ekspektasi operator Hermitian  $L$  pada  $q$  salinan state, memungkinkan evaluasi metrik nonlinier dengan kompleksitas  $O(\epsilon^{-1} q \log N)$ .

## **Implikasi Potensial untuk Machine Learning**

### **1. Penanganan Big Data:**

- Kecepatan logaritmik memungkinkan analisis dataset raksasa (misal,  $10^{90}$  bit) dengan sumber daya komputasi minimal.

### **2. Privasi Data:**

- Akses terbatas ke data mentah mengurangi risiko kebocoran informasi sensitif.

### **3. Integrasi dengan Algoritma Klasik:**

- Subrutin kuantum (misal, kalkulasi jarak) dapat diintegrasikan ke pipeline klasik untuk optimasi parsial.

### **4. Aplikasi di Domain Kompleks:**

- Cocok untuk tugas seperti pengenalan pola, klasifikasi gambar, dan analisis jaringan sosial yang melibatkan vektor berdimensi tinggi.

## **Kelebihan Artikel**

### **1. Dasar Teori Kuat:**

- Penjelasan matematis rigor tentang pemetaan data ke state kuantum dan analisis kompleksitas menggunakan alat seperti qRAM, algoritma Fourier kuantum, dan inversi matriks.

## 2. Generalisasi Luas:

- Algoritma tidak terbatas pada metrik Euclidean; bisa diterapkan ke kernel nonlinier.

## 3. Inovasi Metodologis:

- Penggunaan algoritma adiabatik untuk optimasi klaster, menggabungkan prinsip mekanika kuantum dengan pembelajaran mesin.

## Keterbatasan Artikel

### 1. Ketergantungan pada qRAM:

- Implementasi praktis qRAM masih dalam tahap eksperimental, membatasi aplikasi nyata saat ini.

### 2. Asumsi Idealistik:

- Data diasumsikan sudah terenkripsi dalam bentuk kuantum, sementara konversi data klasik-kuantum belum sepenuhnya terselesaikan.

### 3. Tantangan Algoritma Adiabatik:

- Kinerja bergantung pada *minimum energy gap* selama evolusi Hamiltonian. Jika gap kecil, waktu konvergensi bisa membesar secara eksponensial.

### 4. Output Terbatas:

- Hasil akhir berupa state kuantum  $|\chi\rangle$  hanya bisa diambil sampelnya, sehingga tidak memberikan informasi lengkap tentang semua klaster sekaligus.

## 5. Kompleksitas Implementasi:

- Membutuhkan kendali kuantum presisi tinggi dan stabilitas qubit yang masih menjadi tantangan teknologi.

## Kesimpulan

Artikel ini memberikan terobosan teoretis signifikan dalam *quantum machine learning* dengan menunjukkan potensi percepatan eksponensial untuk tugas pengelompokan. Namun, implementasi praktis masih terhambat oleh keterbatasan teknologi kuantum saat ini, seperti ketersediaan qRAM dan stabilitas qubit. Jika tantangan teknis ini dapat diatasi, algoritma yang diusulkan berpotensi merevolusi analisis data skala besar, terutama di bidang yang memerlukan pemrosesan vektor berdimensi tinggi dengan privasi tinggi.

---

1. What: Apa terobosan teoretis signifikan dalam quantum machine learning yang diusulkan dalam artikel ini?

Artikel ini mengusulkan terobosan fundamental dalam machine learning kuantum melalui dua algoritma utama:

Pertama, algoritma penugasan cluster (cluster assignment) yang dapat menghitung jarak antar vektor dalam waktu logaritmik, dibandingkan algoritma klasik yang

membutuhkan waktu polinomial. Ini berarti untuk dataset besar, komputasi kuantum dapat jauh lebih cepat.

Kedua, algoritma k-means kuantum yang dapat mengelompokkan data dalam waktu  $O(k \log(MN))$ , yang merupakan percepatan eksponensial dibandingkan metode klasik. Algoritma ini menggunakan konsep adiabatik untuk menghasilkan state kuantum yang berisi informasi pengelompokan.

2. Who: Siapa yang berpotensi paling diuntungkan dari algoritma pengelompokan kuantum yang diusulkan?

Beberapa kelompok yang paling berpotensi mendapatkan keuntungan:

- Peneliti big data yang berurusan dengan dataset sangat besar
- Perusahaan teknologi yang memproses jutaan atau miliaran data
- Lembaga riset seperti CERN atau NASA yang menganalisis dataset kompleks
- Institusi keuangan untuk analisis risiko dan pola investasi
- Perusahaan keamanan siber untuk deteksi pola ancaman

3. When: Kapan teknologi kuantum diperkirakan dapat mengatasi hambatan implementasi praktis saat ini?

Para peneliti optimis dalam dekade mendatang (2025-2035). Hambatan utama adalah:

- Pengembangan qRAM (quantum Random Access Memory) yang stabil
- Peningkatan jumlah dan kualitas qubit
- Mengurangi error rate dalam komputasi kuantum
- Menciptakan sistem pendingin yang efisien untuk komputer kuantum

4. Where: Di bidang apa algoritma ini paling berpotensi memberikan dampak revolusioner dalam analisis data?

Beberapa bidang yang paling menjanjikan:

- Genomika: Analisis cepat urutan genetik
- Klimatologi: Pemodelan perubahan iklim
- Jaringan sosial: Analisis jejaring kompleks
- Keuangan: Prediksi pasar dan manajemen risiko
- Kedokteran: Klasifikasi cepat data medis

5. Why: Mengapa algoritma ini dianggap berpotensi merubah paradigma pemrosesan data skala besar?

Keunggulan utamanya adalah:

- Kecepatan eksponensial dalam pemrosesan
- Kemampuan mengolah vektor berdimensi tinggi
- Privasi data yang lebih terjamin
- Efisiensi energi yang lebih baik
- Potensi memproses seluruh data internet dalam waktu singkat

6. How: Bagaimana algoritma kuantum dapat mengatasi keterbatasan komputasi klasik dalam pengelompokan vektor berdimensi tinggi?

Melalui beberapa teknik revolusioner:

- Memanfaatkan superposisi kuantum untuk memproses data simultan
- Menggunakan quantum Fourier transform untuk perhitungan cepat
- Menerapkan algoritma adiabatik untuk optimasi clustering
- Memanfaatkan sifat kuantum untuk menghitung jarak dan kemiripan dalam waktu logaritmik

-----

1. Abstrak



Artikel memperkenalkan algoritma machine learning kuantum yang dapat mengolah vektor dalam ruang berdimensi tinggi dengan kecepatan eksponensial. Algoritma kuantum dapat menyelesaikan tugas pengelompokan data dalam waktu logaritmik, dibandingkan algoritma klasik yang membutuhkan waktu polinomial.

## 2. Pendahuluan

Artikel menjelaskan bahwa machine learning melibatkan manipulasi dan klasifikasi vektor dalam ruang berdimensi tinggi. Komputer kuantum unggul dalam memanipulasi vektor dalam ruang tensor produk. Penelitian sebelumnya telah mengeksplorasi berbagai aspek machine learning kuantum seperti pencocokan pola, klasifikasi biner, dan support vector machines.

## 3. Persiapan Data

Dalam pendekatan kuantum, data awalnya disimpan dalam quantum random access memory (qRAM). Vektor kompleks dapat dikonversi menjadi state kuantum dalam waktu  $O(\log N)$ . Setelah itu, vektor dapat diproses menggunakan transformasi Fourier kuantum, inversi matriks, dan operasi lainnya.

## 4. Supervised Learning: Cluster Assignment

Algoritma ini menunjukkan cara mengassign vektor ke salah satu dari dua kumpulan dengan kompleksitas waktu  $O(\log(MN))$ . Metode ini menggunakan "swap test" dan manipulasi fase kuantum untuk menghitung jarak antar vektor secara efisien.

## 5. Unsupervised Learning: K-Means Clustering

Artikel mengusulkan algoritma Lloyd kuantum untuk k-means clustering. Algoritma ini dapat mengelompokkan  $M$  vektor ke dalam  $k$  cluster dalam waktu  $O(k \log(kMN))$ . Pendekatan adiabatik digunakan untuk menemukan state kuantum yang berisi penugasan cluster.

## 6. Ekstensi ke Metrik Non-Linear

Algoritma jarak kuantum dapat digeneralisasi untuk menggunakan metrik non-linear, memungkinkan perbandingan vektor dengan polinomial derajat tinggi.

## 7. Diskusi

Artikel menekankan kemampuan komputer kuantum dalam memanipulasi vektor berdimensi tinggi. Mereka menunjukkan bahwa operasi yang membutuhkan waktu  $O(N)$  pada algoritma klasik dapat diselesaikan dalam waktu  $O(\log N)$  pada versi kuantum.

Keunggulan Utama:

- Kecepatan eksponensial dalam pemrosesan data

- Privasi data yang lebih baik
- Kemampuan mengolah data skala sangat besar

Tantangan:

- Keterbatasan teknologi kuantum saat ini
- Kebutuhan akan qRAM yang stabil
- Kompleksitas implementasi praktis

Potensi Aplikasi:

- Analisis big data
  - Penelitian genomika
  - Pemodelan iklim
  - Analisis jaringan sosial
  - Keuangan dan manajemen risiko
- 

dengan fokus pada:

- Cara komputasi kuantum dapat mempercepat pengelompokan data (clustering)
- Keunggulan komputasi kuantum dalam mengolah vektor berdimensi tinggi
- Potensi akselerasi eksponensial dibandingkan algoritma klasik
- Metode assignment vector ke cluster dengan waktu logaritmik

